



Image, sécurité et deep learning

Compte-rendu TP5

Réseau de neurones convolutif appliqué à MNIST

Louis Jean

Master 2 IMAGINE
Université de Montpellier
N° étudiant : 21914083

7 octobre 2024

Table des matières

1	Introduction	2
2	Matériel et méthodes	2
3	Résultats et discussions	2
3.1	Précisions obtenues avec différents paramètres	2
3.2	Courbes d'apprentissage	3
4	Conclusion	4

1 Introduction

Les réseaux de neurones convolutifs (CNN) sont des réseaux de neurones particulièrement adaptés pour traiter les données sous forme d'images. Les CNN utilisent des couches convolutives qui permettent d'extraire des caractéristiques locales des images, comme les bords, les textures ou les formes. Le cas pratique proposé dans ce TP consiste à utiliser un CNN pour classer des chiffres manuscrits issus du dataset MNIST.

2 Matériel et méthodes

MNIST contient 70 000 images de chiffres de 0 à 9, et est déjà segmenté en ensembles d'entraînement et de test, respectivement de 60 000 et 10 000 images. Les images, initialement en 28x28 pixels, ont été normalisées pour avoir des valeurs comprises entre 0 et 1. Le modèle CNN implémenté est composé de trois couches convolutives avec des filtres de tailles 3x3, suivies de couches de pooling max 2x2 et d'une couche dense avant la classification finale en 10 classes correspondant aux chiffres de 0 à 9. La fonction d'activation choisie est ReLU, et plusieurs optimiseurs et nombre d'époques sont testés. Le tout a été réalisé en `Python` en utilisant la bibliothèque `tensorflow`, en s'inspirant du code vu en cours.

3 Résultats et discussions

3.1 Précisions obtenues avec différents paramètres

Après l'entraînement du modèle avec plusieurs configurations d'optimiseurs et de nombres d'époques, j'ai obtenu les précisions suivantes sur le jeu de test :


Optimiseur	Époques	Précision (%)
Adam	5	98.62
	10	99.26
SGD	5	98.06
	10	98.86
RMSprop	5	99.06
	10	99.21

Table 1: Précision du modèle avec différents optimiseurs et nombres d'époques


Ces résultats montrent que l'optimiseur RMSprop donne les meilleurs résultats après 5 époques (99,06%) et qu'une augmentation du nombre d'époques améliore globalement la précision du modèle, mais peut-être que la différence ne vaut pas le coût computationnel. Adam et RMSprop se sont avérés très efficaces pour cette tâche de classification.

3.2 Courbes d'apprentissage


J'ai tracé les courbes d'apprentissage pour chaque configuration. Elles montrent comment la précision évolue à la fois sur le jeu d'entraînement et le jeu de test.




(a) Adam, 5 époques




(b) Adam, 10 époques




(c) SGD, 5 époques



(d) SGD, 10 époques



(e) RMSprop, 5 époques



(f) RMSprop, 10 époques

Figure 1: Courbes d'apprentissage pour différents optimiseurs et nombres d'époques

Les courbes d'apprentissage montrent une amélioration continue de la précision au fil des époques, avec peu de signes de surapprentissage. En particulier, l'optimiseur Adam et RMSprop montrent une convergence rapide.

4 Conclusion

Ce projet a permis d'implémenter et d'explorer l'impact de différents optimiseurs et nombres d'époques sur la performance d'un réseau de neurones convolutif appliqué à la classification d'images sur le dataset MNIST. La sélection de l'optimiseur et le nombre d'époques sont des hyperparamètres cruciaux pour atteindre de bonnes performances. Des ajustements supplémentaires comme la régularisation ou l'augmentation de données pourraient encore améliorer ces résultats.

Merci pour le temps et l'attention que vous avez consacrés à la lecture de ce compte-rendu, et encore désolé pour mon absence lors du cours.